

PAEG • AUDIT SERIES

PAEG 审计报告：动态提示词约束

动态提示词约束功能 · 分层放开机制审计

EXECUTIVE CONCLUSION

日期：2026-08-11 触发：用户要求审计"动态调整提示词约束"是否实现——不同场景下，固定提示词和动态补充模板是否有不同层级的放开。结论：**3 位掩码动态约束已实现且工作**（L0 保底 + A/B/C 组按场景放开），但发现 1 处 C 组检测信号词需补充（v0.47 待修）。

日期：2026-08-11 触发：用户要求审计"动态调整提示词约束"是否实现——不同场景下，固定提示词和动态补充模板是否有不同层级的放开。 结论：3 位掩码动态约束已实现且工作（L0 保底 + A/B/C 组按场景放开）， 但发现 1 处 C 组检测信号词需补充（v0.47 待修）。

一、机制确认（完整链路）

6 个模式设置掩码 9 处注入约束层
_set_constraint_flags ———> detect_constraint_flags ———> _build_constraint_layers
(teach×2/answer/method/ (LLM+规则检测) (prompts.py L947)
knowledge/affection) ↓
固定提示词 + 动态约束段
(L0 保底永不放开)

调用点分布：

_set_constraint_flags (6 模式) : server.py L561/L900/L3658/L3807/L3860/L3907 _build_constraint_layers (9 处) : prompts.py L1297 (presenter) /L1707 (chat) /

subagents.py L1528 (answer) /5 handler (method/knowledge/problem/recommend/keyword_doc)

二、3 位掩码设计（prompts.py L881-883）

位	组	含义	触发示例
MASK_A 0b100	A 直接性	取消"直接给答案/列要点/别铺垫"	"直接给我答案，别讲过程"
MASK_B 0b010	B 情绪/温度	取消"情绪/温度/共情/约纳斯克制"	用户要轻松随意
MASK_C 0b001	C 深度/详细度	取消"深度/母语迁移/学科教学法/概念对子"	用户要简化

L0 保底（11 条）永不放开：语言规范/格式/反AI腔核心/安全伦理（L943 确认）

三、验证证据（2026-08-11）

3.1 不同 mask 输出不同（动态生效）

场景	约束段长度	L0	A组	B组	C组
默认(mask=0)	1006 字	☐	☐	☐	☐
取消A(直接答案)	1279 字	☐	放宽说明	☐	☐
取消C(要深度)	1209 字	☐	☐	☐	放宽说明
全放开(mask=111)	1700 字	☐	放宽	放宽	放宽

全放开时明确列出可放宽项： 廉价鼓励/副词/昵称/约纳斯克制/薇依世界观/母语迁移/ 学科教学法/概念对子/subfield_guide/错误纠正 4 层——且"L0 保底约束仍严格生效"。

3.2 掩码场景触发测试

输入	模式	实际 flags	期望	状态
"直接给我答案，别讲过程"	teach	(A,)	A	☐
"我想深入理解这个理论"	teach	()	C	☐☐ 未触发
"随便聊聊，轻松点"	chat	()	B/C	☐☐ 未触发
"今天好累，不想学了"	teach	()	B	☐ (走 affection 门，不算错)
"帮我把这道题解出来"	answer	()	A	☐☐ 未触发 (answer 模式本就要答案)

四、发现的问题 (v0.47 待修)

C 组信号词缺失：constraint_signals.py 的 C 组只检测"简化/概括/一句话/不要深入"——正向深度信号 ("深入/透彻/讲透/本质/详细") 未触发 C 放开。 修复：C 组加正向词 (深入/透彻/讲透/本质/详细/研究级)，命中则取消 C 深度约束 (允许 LLM 讲深)。

A 组在 answer 模式：answer 模式本身要答案，A 触发与否不影响功能 (低优先)。

五、结论

动态提示词约束已实现：固定提示词 (STATIC_TEMPLATES + 静态 system) + 动态补充 (DYNAMIC_SLOTS + 3 位掩码约束段)，不同场景 (mask) 产生不同层级的放开，L0 保底永不跳过。核心链路完整 (6 模式设置 → 检测 → 9 处注入)。1 处增强点：C 组深度正向信号词 (v0.47 补)。