

016 · 动态提示词约束功能审计 (v0.46)

- > 日期: 2026-08-11
- > 触发: 用户要求审计"动态调整提示词约束"是否实现——不同场景下,
- > 固定提示词和动态补充模板是否有不同层级的放开。
- > 结论: 3 位掩码动态约束已实现且工作 (L0 保底 + A/B/C 组按场景放开) ,
- > 但发现 1 处 C 组检测信号词需补充 (v0.47 待修) 。

一、机制确认 (完整链路)

调用点分布:

- `_set_constraint_flags` (6 模式) : `server.py` L561/L900/L3658/L3807/L3860/L3907
- `_build_constraint_layers` (9 处) : `prompts.py` L1297 (presenter) /L1707 (chat) /
`subagents.py` L1528 (answer) /5
`handler` (method/knowledge/problem/recommend/keyword_doc)

二、3 位掩码设计 (prompts.py L881-883)

位	组	含义	触发示例
---	---	---	---
MASK_A 0b100	A 直接性	取消"直接给答案/列要点/别铺垫"	"直接给我答案，别讲过程"
MASK_B 0b010	B 情绪/温度	取消"情绪/温度/共情/约纳斯克制"	用户要轻松随意
MASK_C 0b001	C 深度/详细度	取消"深度/母语迁移/学科教学法/概念对子"	用户要简化

L0 保底 (11 条) 永不放开: 语言规范/格式/反AI腔核心/安全伦理 (L943 确认)

三、验证证据 (2026-08-11)

3.1 不同 mask 输出不同 (动态生效)

	约束段长度	L0	A组	B组	C组
	---	---	---	---	---
	1006 字	□	□	□	□

	1279 字	☐	放宽说明	☐	☐
	1209 字	☐	☐	☐	放宽说明
1)	1700 字	☐	放宽	放宽	放宽

全放开时明确列出可放宽项：廉价鼓励/副词/昵称/约纳斯克制/薇依世界观/母语迁移/学科教学法/概念对子/subfield_guide/错误纠正 4 层——且"L0 保底约束仍严格生效"。

3.2 掩码场景触发测试

输入	模式	实际 flags	期望	状态
	---	---	---	---
接给我答案，别讲过	teach	**(<i>A_i</i>)**	A	☐
想深入理解这个理论"	teach	**()**	C	☐ ☐ 未触发
便聊聊，轻松点"	chat	()	B/C	☐ ☐ 未触发
天好累，不想学了"	teach	()	B	☐ (走 affection 门，不算错)
我把这道题解出来"	answer	()	A	☐ ☐ 未触发 (answer 模式本就要答案)

四、发现的问题 (v0.47 待修)

1. C 组信号词缺失：constraint_signals.py 的 C 组只检测"简化/概括/一句话/不要深入"——正向深度信号 ("深入/透彻/讲透/本质/详细") 未触发 C 放开。
修复：C 组加正向词 (深入/透彻/讲透/本质/详细/研究级) ，
命中则取消 C 深度约束 (允许 LLM 讲深) 。
2. A 组在 answer 模式：answer 模式本身要答案，A 触发与否不影响功能 (低优先) 。

五、结论

动态提示词约束已实现：固定提示词 (STATIC_TEMPLATES + 静态 system) + 动态补充 (DYNAMIC_SLOTS + 3 位掩码约束段) ， 不同场景 (mask) 产生不同层级的放开，L0 保底永不跳过。核心链路完整 (6 模式设置 → 检测 → 9 处注入) 。
1 处增强点：C 组深度正向信号词 (v0.47 补) 。