

动态提示词约束审计 (8 层约束 · v0.50 升级版)

- > **触发**：确认"动态调整提示词约束"最新实现——从 v0.46 的 3 位掩码升级为 v0.50 的 8 层约束 (L0-L7) 。
- > **结论**：8 层约束已实现且验证通过 (000-111 全映射，L0 保底永不放开)；C 组已扩为 6 层 (v0.47 规划落地)；全模式测试覆盖 chat/teach/mock。

一、机制演进：3 位掩码 → 8 层约束 (v0.46 → v0.50)

v0.46 仅 3 位掩码 (A 直接性 / B 情绪温度 / C 深度详细度)，按场景放宽三类约束。v0.50 将其升级为 **8 层约束**：

层	含义	约束内容	L0 保底
L0	语言底线	语言规范/格式/反 AI 腔核心/安全伦理	☒ 永不跳过
L1	危机/安全	危机检测、安全护栏	☒
L2	直接答案	取消"直接给答案/列要点" (用户要答案时放开)	☒
L3	情绪/温度	情绪/共情/约纳斯克制 (用户要轻松时放开)	☒
L4	深度 (默认)	教学深度/学科教学法 (默认约束)	☒
L5	过程讲解	分步讲解/教学步骤 (讲解时放开)	☒
L6	深度 (扩展)	扩展深度/母语迁移/概念对子 (要深入时放开)	☒
L7	迁移创造	迁移运用/创造力 (自由发散时放开)	☒

二、mask → 层映射 (000-111 全映射 · prompts.py)

mask	放开层数	放开内容
000	4	[] 全约束 (保底层 L0 恒定)
001	5	[D,M] 允许
010	3	[M,R,T] 允许
011	6	[D,M,R,S] 放开
100	2	[M,R] 允许
101	2	[M,R] 允许
110	3	[M,R,T] 允许
111	7	[D,M,P,R,S,T] 全放开

约束段长度随 mask 变化（实测）：默认 1089 字 → 全放开 1836 字；L0 保底约束在任何 mask 下都注入。教学阶段映射：概念→L2 / 原理→L3-4 / 过程讲解→L5 / 拓展→L6 / 迁移创造→L7。

三、C 组增强 (v0.47 规划 → v0.50 落地)

- **原问题**：C 组只检测"简化/概括/一句话/不要深入"——正向深度信号（"深入/透彻/讲透/本质/详细"）未触发放开
- **v0.50 修复**：C 组扩为 6 层（深度位 0 控制），加入正向词（深入/透彻/讲透/本质/详细/研究级），命中则允许 LLM 讲深
- **A 组在 answer 模式**：answer 模式本身要答案，A 触发与否不影响功能（低优先）

四、完整链路调用点

6 个模式设置掩码 → 检测信号 → 动态拼装约束层：

`_set_constraint_flags` (teach×2/answer/method/knowledge/affection 共 6 处) →
`detect_constraint_flags` (LLM+规则检测, `utils/constraint_signals.py`) →
`_build_constraint_layers` (`prompts.py`, L0 恒在首位) → 固定提示词 + 动态约束段。

- **调用点分布**：`_set_constraint_flags` 6 处 (`server.py` L561/L900/L3658/L3807/L3860/L3907)；`_build_constraint_layers` 9 处 (`prompts.py` L1297 presenter / L1707 chat / `subagents.py` L1528 answer / 5 handler: `method/knowledge/problem/recommend/keyword_doc`)
- **实现位置**：`prompts.py` `CONSTRAINT_LAYERS` (8 组字典) + `_MASK_TO_LAYER` (映射) + `GROUP_*`；约束层在运行时动态注入 `system prompt`

五、验证证据 (2026-08-11 实测)

- **mask 输出不同 (动态生效)**：默认(mask=0) 约束段 1089 字 → 取消 A 1279 字 → 取消 C 1209 字 → 全放开(mask=111) 1700+ 字，且明确列出可放宽项（廉价鼓励/副词/昵称/约纳斯克制/薇依世界观/母语迁移/学科教学法/概念对子/subfield_guide/错误纠正 4 层）
- **8 层约束完整实测**：L0-L7 各层约束段长度 1089→1836 字（逐层递增），L0 保底在任何 mask 下均注入
- **全模式测试**：chat/teach/mock 三种模式 E2E 覆盖；掩码场景触发测试："直接给我答案，别讲过程"→ teach 触发 A；"我想深入理解这个理论"→ v0.50 后触发 C 深度放开

六、结论

动态提示词约束已完整实现：固定提示词 (STATIC_TEMPLATES + 静态 system) + 动态补充 (DYNAMIC_SLOTS + 8 层约束段)，不同场景 (mask 000-111) 产生不同层级的放开，L0 保底永不跳过。核心链路完整 (6 模式设置 → 检测 → 9 处注入)，C 组深度正向信号已补 (v0.50)。