


多 Agent 架构 · 35 学科 × 4 学段 · 自我进化闭环
PAEG — 让每个学生拥有一位会思考、会调整、会成长的老师



01 教育智能体 技术说明

面向教育场景的智能教学代理：架构、能力矩阵与工程实现

35

学科 × 4 学段

35

54

工具 (含
MCP/skills)

54

9

领域专家 subagent

09

G1-
G11

自我进化闭环

G11

VERSION

v1.1

SVG矢量直出版

DOCUMENT

技术白皮书

Technical Brief

DATE

2026 · 08

项目所有者内部

STATUS

READY

可用

01 PAEG 教育智能体 — 简明技术说明 (v1.1.4)

面向项目所有者：快速恢复对 PAEG 技术实现的全貌认知。结构：TL;DR → 能力全景（每个功能：技术路线 + 实现方法）→ 分层架构 → 关键流程 → 扩展指南。

第 0 章 TL;DR (快速概览)

PAEG 是什么：一个多 Agent 架构的学科教学智能体——不是“给 LLM 套聊天框”，而是让 LLM 扮演“有教学法、有过程、有陪伴、能自我成长”的教师，完成诊断→计划→讲解→评估→调整→自我进化的完整教学闭环。

三大核心能力：1. **智能教学：**像老师一样因材施教（诊断学情→规划路径→逐步讲解→评估掌握→调整策略）2. **学科专精：**35 学科 × 4 学段各有专属教学法（哲学文献论证/大学物理拆键/外语母语迁移...）3. **自我进化：**越用越好——从教学中自动蒸馏知识、沉淀教学经验、热更新知识库，还能用 RALPH 循环持续改进自身

技术底座：Python + Flask（SSE 流式）+ 多种 LLM（DeepSeek/OpenAI 兼容）+ MCP 工具链（25 工具）+ Skills + Workflows + 自我更新引擎。

先认识 5 个关键名词（快速速查）

- **subagent:** 专科老师——每个负责一个领域（诊断/讲解/评估...），职责单一
- **MCP:** 工具调用标准——让 AI 能联网、读写文件、调用外部工具（25 个）
- **Skill:** 按需加载的能力包——需要时才加载的专业流程（11 个）
- **SSE:** 流式推送——AI 边想边输出，像打字机一样逐字显示
- **TRUTH_GROUNDING:** 防幻觉底线——10 条规则强制 AI 不准编造，宁可说“不知道”

第 1 章 项目概览

项	内容
定位	个性化自适应教育智能体 (v0.69)
入口	Web UI (index.html) / REST API (server.py) / 微信桥
技术栈	Python 3.12 / Flask / SSE / MCP / FastMCP / SQLite / JSON 持久化
核心模块	meta_router (意图路由) / paeg (教学编排) / subagents (9 专家) / prompts (提示词库) / self_evolution (自我更新) / config_hub (配置体系) / ralph (循环器)

第 2 章 能力全景 (F1-F7, 每功能含技术路线+实现方法)

F1 智能教学对话

功能	用户场景	技术路线	实现方法
流式教学讲解	问"什么是导数"	意图路由 →Diagnostor→Planner→Presenter→Evaluator	<code>teach_stream</code> (SSE 流式) : diagnosis→plan→step→presentation→evaluation→adjustment 事件序列; Presenter 调 <code>build_presenter_system</code> 组装学科 system + LLM 生成分段讲解, 60 字分片 yield
交互式理解检查	讲完一步问"听懂了吗"	checkpoint 事件 + 前端问答面板	teach_stream 每步 presentation 后发 <code>event: checkpoint</code> (携带复述问题); 前端显示"我理解了/不太清楚/有疑问"按钮, 回答走教学续问
学情诊断	教学前评估学生水平	Diagnostor subagent	前置知识规则检查 + LLM 判断 (<code>recommended_depth/identified_gaps</code>), 输出 JSON
教学策略选择	决定用苏格拉底/支架式/掌握式	pedagogy.choose_strategy	基于诊断 (缺口/深度) + 学科 Bloom 起点 + 画像 (学段/认知风格/目标考试) 选策略, 生成差异化步骤
掌握度评估	判断学生是否学会	Evaluator (纯确定性)	<code>score = 0.6*讲解质量 + 0.4*学生状态</code> ; <code>_student_signal</code> 浅层语义分析 (理解度/困惑/参与/情绪)
教学调整	学生困惑时换讲法	Adapter (纯确定性)	根据 <code>score/confusion/mastery</code> 输出 <code>switch_style/reinforce/continue</code> + 6 种风格选项 (类比/例子优先/苏格拉底/视觉...)
倾诉陪伴	"我压力好大"	AffectionSupportor	三阶段对话 (现象学倾听→薇依注意力→尼采自我克服); 注入完整 WEIL_CORE + TRUTH_GROUNDING; 危机识别 (自伤信号)
找答案	"直接告诉我答案"	AnswerSolver	直接输出完整答案模板 (不走教学引导); 强制检索知识库 + 暴露工具

F2 学科能力矩阵

功能	用户场景	技术路线	实现方法
35 学科 ×4 学段 教学法	各学科因材施教	SUBJECT_STYLES 字典	<code>prompts.py</code> 35 学科独立配置 (<code>persona/language/structure/emphasis/subfield_guide/method_guide/worked_example</code>) , <code>build_presenter_system</code> 按学科条件渲染注入
哲学专项	精读哲学文献	philosophy method_guide	文献论证结构分析 (6 步法) + 概念分析 (6 步法: 概念区分/关系/对子) + 洞穴寓言 worked_example; 考研档解锁
大学物理拆键	大学物理 vs 中学物理	college_physics 独立键	普通物理/四大力学/数学物理方法 subfield_guide + 解题方法论 + 典型例题
外语母语迁移	英语/法语/德语学习	NATIVE_TRANSFER_BLOCK	正迁移 (搭桥) /负迁移 (防御) /易错点 (口诀) /跨文化意识, 仅语言学科注入
考研数学	考研备考	graduate_exam 学段	SUBJECT_GRADES 门控 + SUBFIELD_TREE 二级学科 (考研数学/马原/西哲史...)
学段教学模式差异化	初中/高中/大学/考研讲课风格本质不同	GRADE_TEACHING_MODES + GRADE_SCAFFOLDS	4 学段 × 6 维教学法结构 (初中感官优先:三步可视化/高中结构优先:五步走/大学正式 lecture:五步论证/ 考研考点解剖:五步得分) + 可执行段序列骨架模板 (<code>render_scaffold_to_system</code> → 【NEXT】逐段强 制) ——结构差异 + 内容深度量化 (长度/形式约束) 双落实

F3 学习辅助工具

功能	用户场景	技术路线	实现方法
个性化学习计划	"制定考研数学 90 天计划"	services/planner.py	5 阶段工作流（提取参数→聚合资源→阶段划分→个性化→结构化输出）；阶段骨架确定性 + 里程碑 LLM 个性化；推荐资料附录（用户物料/知识库/联网 4 路聚合）
学习方法建议	"怎么学物理"	services/handlers/method.py	method 意图 → 单次方法建议（非完整计划），注入问卷+约束分层
知识导图	"画知识导图"	knowledge_map + skill	load_skill_knowledge-map 技能 + knowledge_map.py 主动加载
出题/例题	"出一道经典题"	services/handlers/problem.py	出题模板（经典题+完整解答+考查点）；薄弱点优先
文档生成	"生成讲义/要点/例题/笔记"	services/handlers/keyword_doc.py	4 类 doc_type 模板切换，教学对话中关键词触发
学习测评	出选择题	services/quiz_service.py	概念→单选题 JSON（题干/选项/正确索引/解析）
用户反馈	消息气泡 👍 / 🗨️	/api/feedback	前端按钮→feedback_log.jsonl→自我更新消费

F4 自我进化闭环

功能	用户场景	技术路线	实现方法
知识蒸馏	教学后沉淀知识点	distill_knowledge (G1/G2/G7)	教学会话→LLM 提炼→QualityGate L1-L3（含事实评分）→evolved_*.json→G3 热加载→KB 可检索；流式教学 done 后从对话历史抓取（G1）
学科教学补丁	反思改进教学法	subject_patches (G5)	教学反思→战术/战略补丁→memory/subject_patches.md→teaching_memory 注入下次教学
工具经验	工具使用经验沉淀	tool_lessons (G4/G6/G8)	工具调用→LLM 提炼经验（成功信号词判定 G4）→tool_lessons.md（40KB 限长 G8）
知识热加载	更新即时生效	reload_library (G3)	evolved 写入后刷新 KB，无需重启
知识老化归档	旧知识整理	SEL-7	evolved 日文件 >90 天归档 Archive/
用户反馈学习	根据点赞/🗨️改进	/api/feedback (SEL-8)	反馈日志→自我更新消费
RALPH 循环	持续改进任务	ralph/ 子系统	任务执行循环：执行→三层判定（L0 门禁/L1 指标/L2 证据）→承诺协议→防呆五防线（轮次上限/收益递减/质量回退/人类确认/资源熔断）
周度自我更新	定期自动优化	periodic_self_update	洞察/改进建议/学科需求/建议回流/知识归档（时间触发）

F5 多模态产出

功能	用户场景	技术路线	实现方法
讲义/PPT/视频/manim/思维导图	制作教学材料	文件生成器 + MCP	能力清单注入 (_build_capability_manifest) → LLM 判断何时生成 → manim 动画 (manim_service) /PPT (mcp_pptx) /讲义 (keyword_doc) /视频脚本 (script_service) /思维导图 (knowledge_map)
MCP 工具链	联网/文件/检索	25 个 MCP 工具	filesystem/memory/brave-search/pptx 等; config_hub 统一路由 (mcp_ 前缀) , spill 溢出防护 (超 12000 字符截断)
语音朗读	播放回复	/api/voice/tts	前端朗读按钮→TTS
数学可视化视频	生成高质量数学动画	visual_script_generator + manim_service	对话+轮询→script.json (3B1B 原则) →Manim 渲染; 脚本+讲稿+PPT+讲义+思维导图联动可下载
教学视频	授课视频生成	script_service (视频讲稿) + 视频管线	大纲→口语化讲稿 (秒数控制) →合成视频
PPT	教学 PPT 生成	pptx 管线	大纲→LLM 排版→.pptx
讲义/要点/例题/笔记	教学文档生成	keyword_doc	4 类 doc_type 模板, 教学对话关键词触发

F6 配置与扩展体系

功能	用户场景	技术路线	实现方法
统一配置中心	配置 MCP/skills/hooks/workflows	config_hub.py	四子模块统一加载/路由/热更新 (/api/admin/reload)
技能库	按需加载专业能力	skill_registry.py	11 个 skill (teaching-capability/essay-feedback 等) ; L1 目录注入 + L2 按需激活; inject_catalog 统一幂等
钩子系统	事件拦截扩展	hooks_hub.py	7 事件 (session/message/llm/tool) + waterfall 链 + repeat-tool-reminder Guard + timeout 隔离
工作流	声明式流程	workflows_hub.py	teach_minimal/teach_concept DAG (诊断→计划→实施→评估) , run_workflow_ 路由
权限预设	考试模式锁写工具	Permission Preset	read_only/standard/exam/full 四档, exam 禁写工具
动态提示词拼接	LLM 主动调取自我更新补丁	compose_dynamic_prompt tool	LLM 调用返回 subject_patches/tool_lessons/教师笔记 动态段合并
语言规范 MCP 化	语言质量成为可治理服务	lang_gate + forbidden_words.json	统一入口 (13 处收敛 lang_gate_content) + 违禁词数据化 (内嵌 AI_TELLS 去重 555+外部 18) + MCP 三工具 (normalize_text/language_policy_check/forbidden_words) , 外部 agent 可调用

功能	用户场景	技术路线	实现方法
约束引擎 MCP 化	L0-L8 约束可治理/自演进	constraint_engine.py	6 API (layer_get/set/compose/always_active/self_evolve/feedback_adjust) + 数据化落盘 (constraint_layers.json/always_active.json/feedback_log)
sub agent 模型配置化	为每个 subagent 分配不同模型	config_loader.py + config/agents.json	三层合并（内置默认→用户~/paeg→项目）+ {env:}/{file:} 变量替换 + per-subagent LLM 工厂 (provider/model/temperature/max_tokens/thinking_level/enabled) ——用户不改代码即可定制

- **MCP 工具配置驱动 (v1.1.1 §3.36)**：14 个标准化工具由 config/mcp_tools.json 声明 (name/description/risk/module/function/params)，加载器安全动态注册——**改配置即生效** (/api/admin/reload 热重载)，增删工具/调描述/切风险不改代码；四重安全边界（模块白名单/危险模块拒绝/函数名约束/禁 exec）
- **Profile Bundle 分层 (v1.1.3 §3.38 H-2)**：standard/exam/weil 三预设 + bundle 堆叠（默认→bundle→profile→用户覆盖）+ 稀疏 patch ——教师一键切教学场景
- **配置树导出 (v1.1.3 §3.38 H-13)**：/api/admin/dump-config 完整可 patch 配置树（对齐 dsh --dump-config）
- **多级 skill 目录 (v1.1.4 §3.38 A1)**：全局 (skills/) < 项目 (config/skills/) < 用户 (~/paeg/skills/) 三层合并，用户配置支持 {env:KEY|默认}
- **sub agent 模型配置化 (v0.71 §3.32)**：config/agents.json 每 subagent 可配 provider/model/temperature/thinking_level

F7 安全与质量保障

功能	用户场景	技术路线	实现方法
防幻觉底线	不编造事实	TRUTH_GROUNDING	10 条底线（绝不编造/信源为绝对命令/允许说不知道）注入全模式 (presenter/general_chat/affection)，幂等
质量门禁	自我更新入库审核	QualityGate	L1 宪法（有害/注入/PII）→L2 硬规则→L3 LLM 多维评分 (factuality/safety/pedagogy) →L4 证据沙盒
语言规范	输出像人话	LANGUAGE_STYLE + lang_gate + refiner	L1 提示词约束（主谓宾/词法/介词）+ L0/L2 规则+薇依语料矫正 + 违禁词兜底（内嵌 AI_TELLS + 外部 forbidden_words.json 合并）——统一入口 lang_gate_content，MCP 工具化 (§3.28)
安全协议	危机/有害内容	safety.py	危机识别（自伤/自杀）→ 注入指引不短路；有害内容 L1 拦截
事实锚定	真实信息优先	知识库检索 + 联网降级栈	web_search (Brave→Tavily→Serper→Bing 降级)；知识库优先

第 3 章 系统架构（六层）

架构多尺度图（从最大尺度到精细尺度）

图 1 • 全景尺度（PAEG 与外部世界）

参与方	与 PAEG 的关系	数据方向
👤 学生 (浏览器/微信)	服务对象	HTTP/SSE → PAEG
☁️ LLM (DeepSeek/OpenAI)	算力提供者	Prompt → LLM; 生成/工具调用 ←
📖 知识库 (Library/)	记忆与素材	双向 (检索/写入)
🌐 外部世界 (搜索/论文)	信息源	双向 (联网)
💾 持久化 (users_data)	画像/历史存储	双向
🔧 开发者	维护者	热加载注入改进 (虚线)

一句话: PAEG 是大脑, LLM 是算力, 知识库/外部/持久化是记忆与耳目, 学生是服务对象, 开发者通过热加载持续改进。

图示 (Mermaid 渲染) :




图 2 • 系统尺度 (六层 + 一次请求数据流)

层	职责	核心组件	本次请求的角色
L1 用户入口	接收请求	Web UI / REST API / 微信桥	收到提问，发起请求
L2 意图路由	识别意图	meta_router (15 意图)	判定 intent=teach
L3 教学编排	流程控制	paeg.teach / teach_stream (SSE)	五阶段编排 + 流式输出
L4 Subagent	领域执行	9 个领域专家	诊断/计划/讲解/评估协作
L5 能力组件	可复用能力	25 MCP / 11 Skills / Workflows	按需调工具
L6 基础设施	底层支撑	LLM 适配 / 知识库 / config_hub / 持久化	提供算力与数据
L0 横切	质量保障	TRUTH_GROUNDING / QualityGate / 语言规范	约束每一层

一次请求的路径：学生提问 → L1 (POST /api/teach/stream) → L2 (判定 teach) → L3 (五阶段) → L4 (subagent 协作) → L5 (工具按需) → 全程受 L0 约束。

图示 (Mermaid 渲染)：




图 3 • 教学流尺度 (五阶段 + checkpoint 互动)

阶段	执行者	做什么	产出
① 诊断	Diagnostor	前置知识检查 + LLM 深度建议	recommended_depth/identified_gaps
② 计划	Planner	策略选择 + 差异化步骤	3 步教学计划
③ 讲解	Presenter	LLM 流式生成 (60 字分片)	event: presentation
↳ checkpoint	teach_stream	每步后发理解检查问题	event: checkpoint (前端 3 按钮)
④ 评估	Evaluator	score = 0.6·讲解 + 0.4·学生信号	掌握度/困惑信号
⑤ 调整	Adapter	switch/reinforce/continue	下一轮策略
→ 自我进化	self_evolution	蒸馏/补丁/工具经验	evolved 写入 → 热加载 → 知识库可检索

互动循环：讲解 → checkpoint（听懂了吗）→ 学生回答 → 评估（_student_signal）→ 调整 → 继续或重讲；教学完成后自动进入自我进化（蒸馏知识点、沉淀教学补丁、积累工具经验）。

图示（Mermaid 渲染）：





图 4 • 组件尺度 (Presenter 内部装配)

装配块	内容	作用
WEIL_CORE	薇依人格基线	身份与教育信念锚定
TRUTH_GROUNDING	防幻觉 10 条底线	不编造/信源为绝对命令
SUBJECT_STYLES	35 学科风格 (persona/语言/方法论)	因材施教
LANGUAGE_STYLE	语言规范三层	输出像人话
动态补丁	compose_dynamic_prompt	注入自我更新建议

内部流程：确定性装配（上述块）→ system prompt → LLM 调用（重试+超时）→ 60 字分片 → SSE yield；如需工具则经 config_hub 路由到 mcp_ 工具，结果回灌 LLM。

设计原则：确定性骨架（装配/分片/路由）由 Agent 负责，生成由 LLM 负责——这是“教学交给 Agent、生成交给 LLM”的具体实现。

图示（Mermaid 渲染）：



核心调用链（用户问“什么是导数”）

用户输入 → L1(POST /api/teach/stream) → L2(meta_router → intent=teach) → L3(teach_stream: 诊断→计划→讲解→checkpoint→评估→调整) → L4(subagent 协作) → L5(工具按需调用) → L0(防幻觉全程约束)

架构图集（尺度分级·从全景到模块）

图集总览：

尺度	图	覆盖
L0 全景	图1 全景（PAEG 与外部世界）	系统边界

尺度	图	覆盖
L1 系统	图2 六层架构	分层+数据流
L2 教学流	图3 五阶段+checkpoint	一次教学
L3 组件	图4 Presenter 装配	subagent 内部
L4 机制	图5-9（自我进化/RALPH/意图路由/配置体系/checkpoint 时序）	关键机制细节
L5 事件	图9 时序（SSE 事件序列）	流式协议
L6 机制扩充	图20-26（配置驱动/权限双开关/事件类型化/repeat-guard/Profile Bundle/生命周期/物料流水线）	v1.1.x 新增能力

图 5 • 自我进化闭环 (G1-G11)




图 6 • RALPH 循环 (任务驱动持续改进)




图 7 • 意图路由 (meta_router)




图 8 • 配置体系 (config_hub)




图 9 • checkpoint 互动时序 (深入版教学互动)




图 10 • 17 维学生画像正交模型




图 11 • 三层记忆生命周期



图 12 • 教学策略决策树 (choose_strategy)




图 13 • 单步教学续讲 (_pending_steps 状态机)




图 14 • QualityGate L1-L4 四层过滤




图 15 • 周期自我更新调度 (periodic)




图 16 • SSE 流式协议事件序列




图 17 • hooks 事件链 (横切关注点)




图 18 • 危机信号拦截协议 (affection_gate)




图 19 • spill 防护（上下文溢出+注入防御）




图 20 • MCP 工具配置驱动加载器 (v1.1.1 ★)




图 21 • 权限双开关 (sandbox+approval+custom)




图 22 • 事件类型化 (56 类型 + SessionEvent envelope)




图 23 • repeat-tool-guard (chain-key + 多级阈值)




图 24 • Profile Bundle 分层堆叠 + dump-config




图 25 • subagent 生命周期事件 (构造 + start/end + hook)





图 26 • 物料流水线 material_pipeline



第 4 章 关键流程

4.1 教学生命周期 (序列图要点)

诊断(前置+LLM) → 计划(策略+步骤) → 讲解(学科风格+流式) → 检查(理解) → 评估(掌握度) → 调整(下一轮) → 反思(自我更新)

4.2 自我进化闭环 (G1-G11)

教学完成 → 对话历史抓取(G1) → distill 蒸馏(门禁 L1-L3) → evolved 写入(G3 热加载) → KB 可检索; 反思 → subject_patches(G5) → 注入下次教学; 工具经验(G4/G6/G8) → 反馈学习(SEL-8) → 老化归档(SEL-7)

4.3 RALPH 循环

任务提交(TaskRegistry) → 每轮: 执行(executor) → 判定(L0 门禁+L1 指标+L2 证据) → 持久化(快照) → 防呆(五防线) → DONE/ABORT; 承诺协议 <promise>DONE</promise>

4.4 热加载与配置更新

改 config/*.json → POST /api/admin/reload → config_hub.reload_all() → MCP/skills/hooks/workflows 热更新; evolved 写入 → reload_library → KB 即时可见

4.5 防幻觉锚定

TRUTH_GROUNDING 全模式注入（幕等）→ LLM 必须：不编造/信源为绝对命令/允许说不知道 → QualityGate L3 factuality 评分把关自我更新

第 5 章 扩展指南

想做什么	怎么做
新增学科	<code>prompts.py</code> SUBJECT_STYLES 加键 (persona/language/structure/emphasis + 可选 subfield_guide/method_guide/worked_example) + SUBJECT_GRADES/SUBFIELD_TREE
新增 subagent	<code>subagents.py</code> 建类 (run 方法组装 system + 调 _safe_reason_chat) + 注册到 paeg.py
接入 MCP 工具	<code>config/mcp_servers.json</code> 加 server 声明 → 重启/ <code>/api/admin/reload</code> → mcp_ 前缀自动路由
新增 skill	<code>skills/<name>/SKILL.md</code> (frontmatter: name+description + Markdown 正文) → 自动注册
编写 workflow	<code>config/workflows/<name>.json</code> (DAG: steps+depends_on) → run_workflow_ 路由
新增钩子	<code>config/hooks.json</code> 加 {event, module, function} → 事件触发
维护违禁词	<code>normalize_text</code> / <code>language_policy_check</code> / <code>forbidden_words</code> MCP 工具（或直接编辑 data/forbidden_words.json 三类）——动态增删，不改代码
调整约束层	<code>constraint_layer_set</code> MCP 工具（教学/考试/自由层 0-7）或 <code>constraint_always_active</code> 固定永远生效规则
约束自演化	<code>constraint_self_evolve</code> 把教学洞察写入指定层组（落盘 data/constraint_layers.json）
扩充 Library 资料	Library/ 下按级别放置： <code>usr_knowledge/<uid>/</code> （用户级）· <code>Library/<学科>/</code> （学科级）· 公共集（跨学科共享）· 模板与资源库（讲义/PPT/视频模板）—— <code>/api/upload</code> purpose 指定 → 知识库自动索引，BM25 检索可命中

第 5 章附录 可扩展模块（框架化 • v0.70 ★）

框架化原则：所有可扩展能力（约束层级/语言规范/配置体系）都是“**内嵌默认内容 + 外部扩展**”双层结构——PAEG 自身的设计逻辑与内容 100% 保留为内嵌默认，外部开发者可在此基础上更换内容或拓展结构，**不破坏原设计**。

A. 约束层级框架（constraint_engine • §3.29）

框架化确认：是。约束层级已框架化，其他开发者可：

扩展操作	方法	示例
a. 更换每一层内容	编辑 <code>data/constraint_layers.json</code> 的 <code>layers</code> ，同名层整体替换	<code>{"5": ["M", "R", "X"]}</code> 替换 L5 放开组
b. 拓展更多层级	<code>layers</code> 加新键（任意 L8+）， <code>constraint_layer_set(layer=N)</code> 立即生效	<code>{"8": ["M", "R", "T", "D", "S", "P"]}</code> 新增 L8
c. 新增约束组	<code>group_rules</code> 加新组，层定义引用即可	<code>{"X": ["允许比喻"]}</code> + L5 含 X
d. 永远激活	<code>data/always_active.json</code> 的 <code>rules</code> 不随任何层放开	加自定义底线

内嵌默认 (PAEG 原设计完整保留，不可改源码)： - 8 层 (L0 绝对底线 → L7 自由创造) × 6 组开关矩阵 (M 节奏/R 修辞/T 温度/D 教学法深度/S 学科教学法/P 哲学框架) - L0 保底 11 条 (公式 LaTeX/语法完整/反伪共情/三条语言铁律/不重复/不煽情/学科风格/身份不泄漏/危机协议/反 AI 腔/关键信息先判断) - 6 组共 25 条放开规则 (内嵌) - 3 位掩码兼容映射 (MASK_A/B/C → L2-L7)

自省 API： `constraint_layer_scope` (MCP 工具) 返回当前层范围、内嵌/外部来源、可用组、扩展指南——二次开发者可直接调用了解框架。

B. 语言规范框架 (lang_gate • §3.28)

扩展操作	方法
增删违禁词	<code>forbidden_words</code> MCP 工具 (list/add/remove) 或编辑 <code>data/forbidden_words.json</code> 三类 (网络用语/伪共情/套话)
统一入口	所有生成内容过 <code>lang_gate_content</code> (L0 规则 + L2 薇依语料矫正)，外部 agent 可调 <code>normalize_text</code>
内嵌默认	AI_TELLS 577 项 (去重 555) + LANGUAGE_STYLE 规范 + 薇依语料 few-shot——完整保留

C. 配置体系框架 (config_hub)

扩展操作	方法
接 MCP 工具	<code>config/mcp_servers.json</code> 加声明 → <code>/api/admin/reload</code> 热更新
新增 skill	<code>skills/<name>/SKILL.md</code> (frontmatter + 正文) → 自动注册
编写 workflow	<code>config/workflows/<name>.json</code> (DAG) → <code>run_workflow_</code> 路由
新增钩子	<code>config/hooks.json</code> 加 {event, module, function}

第 5A 章 DeepSeek Harness 借鉴蓝图 (2026-08-14 调研)

来源: github.com/deepseek-ai/deepseek-harness (81.5k stars · MIT) ——**一切皆插件** (Everything is a Plugin)，Cordis 驱动。PAEG 依据其架构产出 **30 项优化需求** (§二 Step 2 需求文档, 9 P0 + 14 P1 + 7 P2)。

核心架构五要点（PAEG 已落地部分标注）

dsh 机制	原理	PAEG 对应状态
无特权核心	模型适配器/工具注册表/会话日志/agent 循环全是插件，注册即副作用（卸载自动 unwind）	config_hub 插件体系（MCP/skills/hooks/workflows）✅ 部分对齐
Patch 行级覆盖	YAML <code>- id:</code> 整体替换 config（非 deep merge）； <code>disabled: !!js expr</code> 条件启停	constraint_layers.json 外部层覆盖 ✅ 已用同思想
Profile/Bundle 分层	profile = bundles 堆叠 + 用户 patch + --patch overlay； <code>--dump-config</code> 打印可 patch 树	❌ 待实施（H-2）
事件三分域	session 事件（持久）/ agent 事件（拦截进行中工作）/ 能力事件（fs/tools 接缝）	hooks_hub 7 事件 ✅ 部分对齐
Capability Seam	Service Definition/Provider/Consumer 三角色，换 provider 换全产品	❌ 待实施（H-5/#11）

30 项优化需求速查（完整清单见需求文档 §2 Step 2）

P0（9 项，长期蓝图核心）： #1 subagent patch · #2 profile bundle · #3 persona 外置 · #7 教学预设 · #8 PresetService · #11 三角色重构 · #12 LLM Provider Seam · #13 Shell Seam · #21 Subagent Registry

P1（14 项）： #4 !!js 条件 · #5 home overlay · #9 per-agent scope · #10 preset 结构 · #14 tool 按需加载 · #15 Session Event Log · #18 权限预设升级 · #19 权限事件 · #22 subagent report · #24/25 UI 模式化 · #27 self-update via patch · #29 多级 skill · #30 ctx registry

P2（7 项）： #6 OS 双轨 · #16 hooks 瀑布 · #17 subprocess 抽象 · #20 custom 状态 · #23 fresh-agent loop（对照 RALPH） · #26 HMR · #28 Constitutional patch

建议实施路线（4 阶段，6-10 周）

- **Phase 1 运行时底座**（1-2 周）： #30 ctx registry / #12 LLM Seam / #13 Shell Seam / #15 Session Event Log
- **Phase 2 装扮系统**（2-3 周）： #1 subagent patch / #2 profile / #3 persona / #7-10 预设 / #4-6 条件+overlay
- **Phase 3 能力接缝+权限+UI**（2-3 周）： #11 三角色 / #14 tool registry / #18-20 权限 / #21-23 subagent / #24-26 UI
- **Phase 4 元能力**（1-2 周）： #27 self-update via patch / #28 constitutional patch / #29 多级 skill

衔接：已落地的 constraint_engine（§3.29）+ lang_gate MCP（§3.28）正是 P1 #5/#18/#27 的雏形——约束/语言规范已数据化可动态，后续沿此模式扩展。

第 6 章 未来规划（Roadmap • Oracle 咨询 2026-08-14）

主线：**让现有闭环（教学互动 + 评估 + RALPH）具备生产可用性**——Q3 补齐工程化短板，Q4 教育语义层升级，2027 产品化。每项挂钩九模块薄弱点或调研成果（非空泛目标）。

Q3 近期（1-2 月）：工程化补齐 + 闭环数据沉淀

#	目标	价值	依赖	工作量
Q3-1	timeout-policy（教学长任务分级超时+中断恢复）+ llm-retry 合并入 harness 统一	防长会话卡死/超时	当前 llm-retry	Short
Q3-2	message-feedback 落地：每轮互动 🗣️ / 🗣️ + 文本反馈入库 SQLite	给效果评估提供真实数据	message-feedback 子包	Short
Q3-3	session-sqlite 全量替换：会话状态内存/JSON → SQLite（回放）	会话可审计可回放（合规必需）	现有会话管理	Short
Q3-4	九模块薄弱点扫描：对照 §3.12 产出评估覆盖率矩阵	让 Roadmap 可量化	§3.12 文档	Quick
Q3-5	教学能力结构化 v2：teaching-capability 接入 TPACK/加涅元数据标注	能力体系真正接入运行	teaching-capability	Short

Q3 退出条件：生产会话零丢失；≥30% 会话带反馈数据；九模块覆盖矩阵公开。

Q4 中期（3-4 月）：教育语义层 + 上下文工程统一

#	目标	价值	依赖	工作量
Q4-1	记忆系统语义分层（working/episodic/semantic + 教学知识图谱）	解耦对话与长期认知图谱	Q3-3/Q3-5	Medium
Q4-2	教育知识图谱 MVP（教资 8 模块 × 专业标准 6 能力 × ADDIE）	诊断/画像有“该教什么”依据	教育体系调研	Medium
Q4-3	多 agent 协作（教师+学生+评估 Agent，RALPH 编排不换框架）	Berliner 专家级反思 + LLM-as-judge	Q4-1/ralph	Medium
Q4-4	上下文工程全量统一（预算分配 + 知识图谱检索槽位）	防长会话丢关键上下文	runoob 调研/compaction	Short
Q4-5	RAG 接入语义层（反馈+能力标注+知识图谱为检索源）	画像/策略有据可查	Q4-1/Q4-2/Q3-2	Medium

Q4 退出条件：同一学生 3 次会话可复现认知图谱；多 agent 评估与人工一致率 ≥70%。

2027 远期：产品化方向

#	方向	触发条件	里程碑	工作量
Y-1	个性化自适应闭环成熟（诊断→画像→差异化→评估→反馈全自动）	Q4-3 跑通 ≥1 学科	自适应学习案例	Large
Y-2	教师协作平台（班级薄弱点洞察 + 干预建议 + 策略编辑）	反馈数据 ≥6 个月	教师端 dashboard	Large
Y-3	多模态教学（板书/公式 OCR、语音、图形化思维呈现）	用户具体需求	≥1 学科可用	Large
Y-4	数据洞察 + 学习分析（知识图谱薄弱热力图）	Q4-2 有真实数据	分析报告	Medium

价值-成本矩阵（优先做 ★★★→★★→★）

	低成本	中成本	高成本
高价 值	Q3-1 timeout ★、Q3-3 sqlite ★、Q4-4 上下文统一 ★	Q4-1 记忆分层 ★★、Q4-2 知识图谱 ★★、Q4-3 多 agent ★★	Y-1 自适应闭环 ★★★、Y-2 教师协作 ★★
中价 值	Q3-2 feedback、Q3-5 能力标注	Q4-5 RAG、Y-4 数据洞察	Y-3 多模态
低价 值	Q3-4 评估矩阵	—	—

决策规则（项目所有者）

1. 每条 Roadmap 项必须挂钩：九模块薄弱点 / 教育体系能力 / Harness 包——空泛项砍掉
2. 季度回顾硬指标：Q3 看"零丢失+反馈入库率"，Q4 看"认知图谱可复现"，2027 看"教师实际干预次数"
3. 多 agent 不换框架（复用 RALPH）；知识图谱先轻量本体（JSON）确认需求再上 Neo4j

附录 A 术语表

术语	含义
meta_router	意图路由器（15 意图分类，LLM 优先+规则兜底+模式短路）
SUBJECT_STYLES	35 学科教学风格字典（persona/语言/结构/侧重/方法论/例题）
subagent	领域专家子代理（9 个，职责单一+上下文隔离）
MCP	Model Context Protocol——工具链（filesystem/brave-search 等 25 工具）
Skill	按需加载的专业能力（SKILL.md，L1 目录+L2 激活）
Workflow	声明式流程（JSON DAG，如 teach_minimal 诊断→计划→实施→评估）
hooks	事件钩子（session/message/llm/tool 7 类，waterfall 链）
TRUTH_GROUNDING	防幻觉底线（10 条，全模式注入）
QualityGate	自我更新质量门禁（L1-L4）
RALPH	任务驱动持续改进循环（ralph/ 子系统）
SSE	Server-Sent Events（流式教学输出协议）

附录 B 核心文件索引

文件	职责
server.py	Flask 入口（所有端点 + teach_stream SSE）

文件	职责
paeg.py	教学编排主链 (teach() 五阶段)
subagents.py	9 个 subagent + Presenter + 能力清单
prompts.py	提示词库 (WEIL_CORE/TRUTH_GROUNDING/SUBJECT_STYLES/build_*_system)
meta_router.py	15 意图路由
self_evolution.py	自我更新 (蒸馏/补丁/工具经验/老化)
config_hub.py	配置中心 (MCP/skills/hooks/workflows 统一)
ralph/	RALPH 循环子系统 (6 模块)
pedagogy.py	教学策略选择 (画像驱动)
constraint_engine.py	L0-L8 约束引擎 (6 API: layer_get/set/compose/always_active/self_evolve/feedback_adjust)
services/lang_gate.py	语言规范统一入口 (L0+L2 守门, 13 处收敛)
language_refiner.py	薇依语料矫正 (AI_TELLS + forbidden_words.json 合并)
services/	场景 handler (method/study_plan/quiz/keyword_doc 等) + planner + 生产管线
data/forbidden_words.json	外部违禁词数据 (extra_forbidden/pseudo_empathy_verbs/ai_tells_extra)
data/constraint_layers.json	外部约束层覆盖 (self_evolve 落盘)
data/always_active.json	永远激活规则 (外部维护)
config_loader.py	sub agent 配置加载器 (三层合并 + 变量替换 + create_llm_for)
config/agents.json	10 subagent 模型配置 (provider/model/temperature/max_tokens/thinking_level)
09_GUI前端/index.html	Web UI (含 checkpoint 问答面板/反馈按钮)

附录 C 技术创新亮点 (v0.70 🌟)

展示 PAEG 核心技术创新的**原创设计亮点**——每个都是“独立设计思想 + 可框架化/可扩展 + 构成技术壁垒”的量级。全规范模块与动态约束模块为本次 v0.70 新增的并列双亮点。

C.1 全规范模块：语言规范 MCP 化 (\$3.28)

一句话：把“语言像真人”从散落的函数调用升级为**统一入口 + 外部数据 + 标准工具**的可治理服务——外部 agent 也能调用 PAEG 的语言规范能力。

维度	内容
统一入口	13 处 <code>_polish_text</code> 收敛为 <code>lang_gate_content</code> (L0 规则检测 + L2 薇依语料深度矫正双守门)，调用点不散调

维度	内容
违禁词数据化	<code>forbidden_words.json</code> 外部数据源（网络用语/伪共情/套话三类）， <code>language_refiner</code> 启动合并内嵌 AI_TELLS（577 项去重 555 + 外部 18），文件缺失容错
MCP 三工具	<code>normalize_text</code> （生成内容统一过语言规范） / <code>language_policy_check</code> （AI 味概率+违禁词命中，不调 LLM 零成本） / <code>forbidden_words</code> （list/add/remove 动态维护禁词，不改代码）
示例	<code>normalize_text("简单来说，这个公式的推导很关键，加油！")</code> → "这个公式的推导是关键的。我们来说明一下它的来龙去脉。"
创新点	①语言规范独立于模型性能（L1 提示词约束 + L0/L2 规则矫正 + 违禁词兜底三层）②MCP 化使外部智能体可复用 ③数据化可动态治理（对应元能力"标准化工具开发"4 原则）

C.2 动态约束模块：L0-L8 约束引擎 MCP 化 (§3.29)

一句话：L0-L8 分层约束从"prompts.py 常量"升级为**6 API 约束引擎 + 可框架化扩展**——动态切换层、任意组合、永远激活、自我演化、反馈调强，全部数据化落盘。

维度	内容
6 API 全覆盖	<code>layer_get</code> （读层放开组） / <code>layer_set</code> （动态切换教学/考试/自由，支持外部扩展层） / <code>compose</code> （任意提示词块拼接） / <code>always_active</code> （永远激活不随层放开） / <code>self_evolve</code> （教学洞察自动提炼入层） / <code>feedback_adjust</code> （"太啰嗦→放宽节奏、太深→收紧深度"信号映射）
框架化	内嵌 8 层 × 6 组（PAEG 原设计完整保留）+ 外部 JSON 可更换层内容/拓展 L8+ 层级/新增组； <code>constraint_layer_scope</code> 框架自省 API
示例	<code>constraint_feedback_adjust("你讲得太啰嗦了")</code> → 检测到『啰嗦』→ 建议放宽节奏组(M) + 落盘反馈日志； <code>constraint_self_evolve("分步讲解时先给结论再展开")</code> → 自动写入 L5 组 M
创新点	①8 层线性约束谱（L0 绝对底线→L7 自由创造，crisis 强制 L1）②"约束"作为可治理资源（自演进/反馈调强=agent 自创生性）③框架化双层结构（内嵌默认+外部扩展）

C.3 同等量级技术创新一览 (explore 调研确认 • 2026-08-14)

与 C.1/C.2 旗鼓相当的项目内技术创新（按"框架化深度 × MCP/插件化形态 × 不可复制壁垒"三维度评估）。

等级	亮点	核心创新机制	实现证据
A+	RALPH 持续改进子系统	6 模块任务驱动循环：Verdict 承诺协议（DONE/CONTINUE/ABORT）+ L0-L2 三层完成判定 + 五道防线防呆（轮次上限/收益递减/质量回退/人类确认/资源熔断）+ 任务注册表持久化 + 优先级队列	ralph/ 6 模块 (contracts/loop_controller/completion_evaluator/termination_guard/task_registry)
A+	插件生态中枢 (config_hub 三件套)	MCP/Skills/Hooks/Workflows 四子 hub 统一注册 + 热更新 + waterfall+next() 钩子链 + matcher 引擎 + DAG 工作流 + 两道防护 (repeat_guard 防重复调用循环 + spill_guard 防上下文爆掉)	config_hub.py + hooks_hub.py + workflows_hub.py + config/*.json

等级	亮点	核心创新机制	实现证据
A	17 维学生画像 Individuality	16+1 维正交 dataclass + L1/L2/L3 三级注入 + add_dimension 动态扩展（加到第 18/19 维不破坏 to_prompt）+ 增量建模 merge 算法 + 五层注入控制（语言/风格/深度/节奏/情绪）+ 持久化闭环	student_trait.py (956 行) + subagents.py Individuality
A-	3B1B 数学可视化剧本生成器	8 项铁律形式化（渐进揭示/单一聚焦/颜色语义/节奏/文字最小化/构图/回看锚点/依赖显式）+ 5 段式 JSON Schema + 校验修补循环（失败→重生成最多 2 轮）——3B1B 方法论工程化封装	visual_script_generator.py + visual_script_validator.py

C.4 自我更新模块（四路自进化 + 质量门禁闭环 · F4 展开）

一句话：PAEG 的自我更新不是“记录日志”，而是**四路进化 + 四层门禁 + 热加载闭环**的完整自成长系统——每次教学都沉淀为下一次教学的能力。

维度	内容
四路进化	①知识蒸馏（教学→LLM 提炼→evolved_*.json）②提示词补丁（反思→subject_patches.md→注入下次教学）③工具经验（工具成败→LLM 提炼→tool_lessons.md, 40KB 限长）④学科需求闭环（用户问新学科→记录→反馈）
四层门禁 QualityGate	L1 宪法硬规则（有害/注入/PII）→ L2 长度去重 → L3 LLM 多维评分（factuality/safety/pedagogy）→ L4 证据沙盒
热加载闭环	evolved 写入→reload_library→KB 即时可检索（G3, 无需重启）
被动 + 主动双子生态	四路自进化（被动，教学后沉淀）+ RALPH 循环（主动，任务驱动持续改进）——自成长双引擎
动态提示词拼接	compose_dynamic_prompt tool: LLM 主动调取 subject_patches/tool_lessons/教师笔记动态段，与固定 system 合并
创新点	①蒸馏有门禁（不是什么都进）②失败案例也可提炼（ReasoningBank 反直觉）③G1-G11 闭环全验证（流式蒸馏/门禁澄清/热加载/教学记忆/LLM 提炼）

C.5 更多亮点速览（简明）

亮点	一句话
哲学三角情绪支持	胡塞尔（如何看）+ 薇依（为何看）+ 尼采（看完后重新站立）+ 危机协议（先回应再关怀 + 12356 热线 + 尊重拒绝）——不可复制的价值观壁垒
防幻觉底层约束	TRUTH_GROUNDING 10 条底线（不编造/信源为绝对命令/允许说不知道）注入全模式，幕等兜底
九模块教学底座	诊断→计划→呈现→评估→调整→反思→自更新完整闭环，评估用确定性启发式（可复现不随机）
三层记忆	SESSIONS 短期 + 画像长期 + 教学记忆语义层（token 估算 + 摘要压缩）
教学物料 workflow	teach_materials DAG：一个主题→6 类物料（知识导图/讲义/PPT/讲稿/视频脚本/数学动画）联动可下载

亮点	一句话
权限预设	read_only/standard/exam/full 四档，exam 锁写工具（借鉴 deepseek-harness）

C.6 MCP 工具可移植性：配置驱动加载器 (v1.1.1 §3.36 ★)

语言规范/约束引擎/物料流水线等 14 个标准化工具升级为**配置驱动**——mcp_tools_loader.py 把 config/mcp_tools.json 声明翻译为可注册工具（白名单+三重校验+异常隔离），/api/admin/reload 热重载即生效（14/14 与配置一致），外部项目可整套移植（附手册）。安全边界四重：模块前缀白名单 / 危险模块拒绝（os/sys/subprocess/importlib...） / 函数名非下划线 / 永不 exec。

C.7 运行可治理三件套 (v1.1.2-1.1.3 §3.37/§3.38 ★)

- **权限双开关 (#18)**：sandbox + approval 命名组合——Opplly("exam") 一键锁写工具+禁审批；custom 派生防误判；意图事件可回放审计（services/permission.py）
- **repeat-tool-guard (H-16)**：chain-key 精确计数（同工具不同参数不算重复）+ 多级阈值 [3,5,8] + 用户插话重置——防 AI 死循环（hooks_hub）
- **事件类型化 (H-1/H-12)**：56 个已知事件类型 + SessionEvent envelope（seq/time/data/surfaceOp）——拼错类型立即报错，surface 事件强制校验（infra/event_types.py）

C.8 subagent 生命周期事件 + 多级 skill (v1.1.4 §3.38 ★)

- **subagent/descriptor**：构造时 9 个 subagent 各一个；**tool-workflow/agent-start/end**：每个 .run() 前后成对（runId UUID 配对 + duration_ms），teach 直调与 workflow 路径双覆盖；hook/invoked/result 包裹钩子链——调试像看剧本
- **多级 skill**：~/paeg/skills.json（）+ {env:KEY|默认} 替换——用户级技能覆盖项目/全局

附录 D 需求文档即 workflow 中枢 (2026-08-14 ★)

工程治理原则：PAEG_任务总清单与操作规范.md 是项目的**workflow 规范中枢**——提出执行标准、工作纪律，并记录需求更新迭代情况。技术/维护/元能力/亮点各文档都从它派生。

三大职能：1. **执行标准**：操作纪律（git 铁律/引号铁律/正则 AST 铁律/运行卡住 SOP/更新及时记文档/subagent 结果及时移入项目）、任务核对、完成验证（无证据=未完成）、调研落盘、进程管理 2. **工作纪律**：任务先记录（先写需求文档再动手）/ 实时更新状态（✅🔄⏸️ 不批量）/ 借鉴外部项目记录来源 / 每项完成即验证 + 文档落盘 3. **需求更新迭代记录**：§3.x 按时间顺序记录每次需求（来源/现状/方案/实施记录/验证）——需求的唯一真相源

workflow：任务核对 → 按优先级执行 → 每项完成更新状态 → 完成验证 → 调研落盘 → 重大改动回归 → 更新技术快照

元技能：“先记录，后执行”是第一纪律——需求文档是记忆的外部化、版本化的决策日志；没有需求文档的工作流不可追溯、不可复盘、不可交接。