


多 Agent 架构 · 35 学科 × 4 学段 · 自我进化闭环
PAEG — 让每个学生拥有一位会思考、会调整、会成长的老师



01 教育智能体 技术说明

面向教育场景的智能教学代理：架构、能力矩阵与工程实现



VERSION	DOCUMENT	DATE	STATUS
v0.70 正式交付版	技术白皮书 Technical Brief	2026 · 08 项目所有者内部	READY 可用

01 PAEG 教育智能体 — 简明技术说明 (v0.69)

面向项目所有者：快速恢复对 PAEG 技术实现的全貌认知。结构：TL;DR → 能力全景（每个功能：技术路线 + 实现方法）→ 分层架构 → 关键流程 → 扩展指南。

第 0 章 TL;DR（快速概览）

PAEG 是什么：一个多 Agent 架构的学科教学智能体——不是"给 LLM 套聊天框"，而是让 LLM 扮演"有教学法、有过程、有陪伴、能自我成长"的教师，完成诊断→计划→讲解→评估→调整→自我进化的完整教学闭环。

三大核心能力： 1. **智能教学：**像老师一样因材施教（诊断学情→规划路径→逐步讲解→评估掌握→调整策略） 2. **学科专精：**35 学科 × 4 学段各有专属教学法（哲学文献论证/大学物理拆键/外语母语迁移...） 3. **自我进化：**越用越好——从教学中自动蒸馏知识、沉淀教学经验、热更新知识库，还能用 RALPH 循环持续改进自身

技术底座：Python + Flask (SSE 流式) + 多种 LLM (DeepSeek/OpenAI 兼容) + MCP 工具链 (25 工具) + Skills + Workflows + 自我更新引擎。

先认识 5 个关键名词（快速速查）

- subagent:** 专科老师——每个负责一个领域（诊断/讲解/评估...），职责单一
- MCP:** 工具调用标准——让 AI 能联网、读写文件、调用外部工具 (25 个)
- Skill:** 按需加载的能力包——需要时才加载的专业流程 (11 个)
- SSE:** 流式推送——AI 边想边输出，像打字机一样逐字显示
- TRUTH_GROUNDING:** 防幻觉底线——10 条规则强制 AI 不准编造，宁可说"不知道"

第 1 章 项目概览

项	内容
定位	个性化自适应教育智能体 (v0.69)
入口	Web UI (index.html) / REST API (server.py) / 微信桥
技术栈	Python 3.12 / Flask / SSE / MCP / FastMCP / SQLite / JSON 持久化
核心模块	meta_router (意图路由) / paeg (教学编排) / subagents (9 专家) / prompts (提示词库) / self_evolution (自我更新) / config_hub (配置体系) / ralph (循环器)

第 2 章 能力全景 (F1-F7，每功能含技术路线+实现方法)

F1 智能教学对话

功能	用户场景	技术路线	实现方法
流式教学讲解	问"什么是导数"	意图路由 →Diagnostor→Planner→Presenter→Evaluator	<code>teach_stream</code> (SSE 流式) : diagnosis→plan→step→presentation→evaluation→adjustment 事件序列; Presenter 调 <code>build_presenter_system</code> 组装学科 system + LLM 生成分段讲解, 60 字分片 yield
交互式理解检查	讲完一步问"听懂了吗"	checkpoint 事件 + 前端问答面板	<code>teach_stream</code> 每步 presentation 后发 <code>event: checkpoint</code> (携带复述问题); 前端显示"我理解了/不太清楚/有疑问"按钮, 回答走教学续问
学情诊断	教学前评估学生水平	Diagnostor subagent	前置知识规则检查 + LLM 判断 (recommended_depth/identified_gaps), 输出 JSON
教学策略选择	决定用苏格拉底/支架式/掌握式	pedagogy.choose_strategy	基于诊断(缺口/深度) + 学科 Bloom 起点 + 画像(学段/认知风格/目标考试) 选策略, 生成差异化步骤
掌握度评估	判断学生是否学会	Evaluator (纯确定性)	<code>score = 0.6*讲解质量 + 0.4*学生状态</code> ; <code>_student_signal</code> 浅层语义分析(理解度/困惑/参与/情绪)
教学调整	学生困惑时换讲法	Adapter (纯确定性)	根据 score/confusion/mastery 输出 switch_style/reinforce/continue + 6 种风格选项(类比/例子优先/苏格拉底/视觉...)
倾诉陪伴	"我压力好大"	AffectionSupportor	三阶段对话(现象学倾听→微依注意力→尼采自我克服); 注入完整 WEIL_CORE + TRUTH_GROUNDING; 危机识别(自伤信号)
找答案	"直接告诉我答案"	AnswerSolver	直接输出完整答案模板(不走教学引导); 强制检索知识库 + 暴露工具

F2 学科能力矩阵

功能	用户场景	技术路线	实现方法
35 学科 ×4 学段 教学法	各学科因材施教	SUBJECT_STYLES 字典	<code>prompts.py</code> 35 学科独立配置 (persona/language/structure/emphasis/subfield_guide/method_guide/worked_example) , <code>build_presenter_system</code> 按学科条件渲染注入
哲学专项	精读哲学文献	philosophy method_guide	文献论证结构分析 (6 步法) + 概念分析 (6 步法: 概念区分/关系/对子) + 洞穴寓言 worked_example; 考研档解锁
大学物理拆键	大学物理 vs 中学物理	college_physics 独立键	普通物理/四大力学/数学物理方法 subfield_guide + 解题方法论 + 典型例题
外语母语迁移	英语/法语/德语学习	NATIVE_TRANSFER_BLOCK	正迁移 (搭桥) /负迁移 (防御) /易错点 (口诀) /跨文化意识, 仅语言学科注入
考研数学	考研备考	graduate_exam 学段	SUBJECT_GRADES 门控 + SUBFIELD_TREE 二级学科 (考研数学/马原/西哲史...)

F3 学习辅助工具

功能	用户场景	技术路线	实现方法
个性化学习计划	"制定考研数学 90 天计划"	services/planner.py	5 阶段工作流 (提取参数→聚合资源→阶段划分→个性化→结构化输出) ; 阶段骨架确定性 + 里程碑 LLM 个性化; 推荐资料附录 (用户物料/知识库/联网 4 路聚合)
学习方法建议	"怎么学物理"	services/handlers/method.py	method 意图 → 单次方法建议 (非完整计划) , 注入问卷+约束分层

功能	用户场景	技术路线	实现方法
知识导图	"画知识导图"	knowledge_map + skill	load_skill_knowledge-map 技能 + knowledge_map.py 主动加载
出题/例题	"出一道经典题"	services/handlers/problem.py	出题模板（经典题+完整解答+考查点）；薄弱点优先
文档生成	"生成讲义/要点/例题/笔记"	services/handlers/keyword_doc.py	4 类 doc_type 模板切换，教学对话中关键词触发
学习测评	出选择题	services/quiz_service.py	概念→单选题 JSON（题干/选项/正确索引/解析）
用户反馈	消息气泡 👍 / 🗨️	/api/feedback	前端按钮→feedback_log.jsonl→自我更新消费

F4 自我进化闭环

功能	用户场景	技术路线	实现方法
知识蒸馏	教学后沉淀知识点	distill_knowledge (G1/G2/G7)	教学会话→LLM 提炼→QualityGate L1-L3（含事实评分）→evolved_*.json→G3 热加载→KB 可检索；流式教学 done 后从对话历史抓取（G1）
学科教学补丁	反思改进教学法	subject_patches (G5)	教学反思→战术/战略补丁→memory/subject_patches.md→teaching_memory 注入下次教学
工具经验	工具使用经验沉淀	tool_lessons (G4/G6/G8)	工具调用→LLM 提炼经验（成功信号词判定 G4）→tool_lessons.md（40KB 限长 G8）
知识热加载	更新即时生效	reload_library (G3)	evolved 写入后刷新 KB，无需重启
知识老化归档	旧知识整理	SEL-7	evolved 日文件 >90 天归档 Archive/
用户反馈学习	根据点赞/🗨️改进	/api/feedback (SEL-8)	反馈日志→自我更新消费
RALPH 循环	持续改进任务	ralph/ 子系统	任务执行循环：执行→三层判定（L0 门禁/L1 指标/L2 证据）→承诺协议→防呆五防线（轮次上限/收益递减/质量回退/人类确认/资源熔断）
周度自我更新	定期自动优化	periodic_self_update	洞察/改进建议/学科需求/建议回流/知识归档（时间触发）

F5 多模态产出

功能	用户场景	技术路线	实现方法
讲义/PPT/视频/manim/思维导图	制作教学材料	文件生成器 + MCP	能力清单注入 (_build_capability_manifest) → LLM 判断何时生成 → manim 动画 (manim_service) /PPT (mcp_pptx) /讲义 (keyword_doc) /视频脚本 (script_service) /思维导图 (knowledge_map)
MCP 工具链	联网/文件/检索	25 个 MCP 工具	filesystem/memory/brave-search/pptx 等; config_hub 统一路由 (mcp_ 前缀) , spill 溢出防护 (超 12000 字符截断)
语音朗读	播放回复	/api/voice/tts	前端朗读按钮→TTS

F6 配置与扩展体系

功能	用户场景	技术路线	实现方法
统一配置中心	配置 MCP/skills/hooks/workflows	config_hub.py	四子模块统一加载/路由/热更新 (/api/admin/reload)
技能库	按需加载专业能力	skill_registry.py	11 个 skill (teaching-capability/essay-feedback 等) ; L1 目录注入 + L2 按需激活; inject_catalog 统一幂等
钩子系统	事件拦截扩展	hooks_hub.py	7 事件 (session/message/llm/tool) + waterfall 链 + repeat-tool-reminder Guard + timeout 隔离
工作流	声明式流程	workflows_hub.py	teach_minimal/teach_concept DAG (诊断→计划→实施→评估) , run_workflow_ 路由
权限预设	考试模式锁写工具	Permission Preset	read_only/standard/exam/full 四档, exam 禁写工具
动态提示词拼接	LLM 主动调取自我更新补丁	compose_dynamic_prompt tool	LLM 调用返回 subject_patches/tool_lessons/教师笔记 动态段合并

F7 安全与质量保障

功能	用户场景	技术路线	实现方法
防幻觉底线	不编造事实	TRUTH_GROUNDING	10 条底线 (绝不编造/信源为绝对命令/允许说不知道) 注入全模式 (presenter/general_chat/affection) , 幂等
质量门禁	自我更新入库审核	QualityGate	L1 宪法 (有害/注入/PII) →L2 硬规则→L3 LLM 多维评分 (factuality/safety/pedagogy) →L4 证据沙盒
语言规范	输出像人话	LANGUAGE_STYLE + polish/refiner	三层语言规范 (主谓宾/词法/介词) + 薇依语料矫正 + 反 AI 腔

功能	用户场景	技术路线	实现方法
安全协议	危机/有害内容	safety.py	危机识别（自伤/自杀）→ 注入指引不短路；有害内容 L1 拦截
事实锚定	真实信息优先	知识库检索 + 联网降级栈	web_search（Brave→Tavily→Serper→Bing 降级）；知识库优先

第 3 章 系统架构（六层）

架构多尺度图（从最大尺度到精细尺度）

图 1 • 全景尺度（PAEG 与外部世界）

参与方	与 PAEG 的关系	数据方向
👤 学生（浏览器/微信）	服务对象	HTTP/SSE → PAEG
🧠 LLM（DeepSeek/OpenAI）	算力提供者	Prompt → LLM；生成/工具调用 ←
📖 知识库（Library/）	记忆与素材	双向（检索/写入）
🌐 外部世界（搜索/论文）	信息源	双向（联网）
💾 持久化（users_data）	画像/历史存储	双向
🔧 开发者	维护者	热加载注入改进（虚线）

一句话：PAEG 是大脑，LLM 是算力，知识库/外部/持久化是记忆与耳目，学生是服务对象，开发者通过热加载持续改进。

图 2 • 系统尺度（六层 + 一次请求数据流）

层	职责	核心组件	本次请求的角色
L1 用户入口	接收请求	Web UI / REST API / 微信桥	收到提问，发起请求
L2 意图路由	识别意图	meta_router（15 意图）	判定 intent=teach
L3 教学编排	流程控制	paeg.teach / teach_stream（SSE）	五阶段编排 + 流式输出
L4 Subagent	领域执行	9 个领域专家	诊断/计划/讲解/评估协作
L5 能力组件	可复用能力	25 MCP / 11 Skills / Workflows	按需调工具
L6 基础设施	底层支撑	LLM 适配 / 知识库 / config_hub / 持久化	提供算力与数据
L0 横切	质量保障	TRUTH_GROUNDING / QualityGate / 语言规范	约束每一层

一次请求的路径：学生提问 → L1 (POST /api/teach/stream) → L2 (判定 teach) → L3 (五阶段) → L4 (subagent 协作) → L5 (工具按需) → 全程受 L0 约束。

图 3 • 教学流尺度 (五阶段 + checkpoint 互动)

阶段	执行者	做什么	产出
① 诊断	Diagnostor	前置知识检查 + LLM 深度建议	recommended_depth/identified_gaps
② 计划	Planner	策略选择 + 差异化步骤	3 步教学计划
③ 讲解	Presenter	LLM 流式生成 (60 字分片)	event: presentation
↳ checkpoint	teach_stream	每步后发理解检查问题	event: checkpoint (前端 3 按钮)
④ 评估	Evaluator	score = 0.6·讲解 + 0.4·学生信号	掌握度/困惑信号
⑤ 调整	Adapter	switch/reinforce/continue	下一轮策略
→ 自我进化	self_evolution	蒸馏/补丁/工具经验	evolved 写入 → 热加载 → 知识库可检索

互动循环：讲解 → checkpoint (听懂了吗) → 学生回答 → 评估 (_student_signal) → 调整 → 继续或重讲；教学完成后自动进入自我进化 (蒸馏知识点、沉淀教学补丁、积累工具经验)。

图 4 • 组件尺度 (Presenter 内部装配)

装配块	内容	作用
WEIL_CORE	薇依人格基线	身份与教育信念锚定
TRUTH_GROUNDING	防幻觉 10 条底线	不编造/信源为绝对命令
SUBJECT_STYLES	35 学科风格 (persona/语言/方法论)	因材施教
LANGUAGE_STYLE	语言规范三层	输出像人话
动态补丁	compose_dynamic_prompt	注入自我更新建议

内部流程：确定性装配 (上述块) → system prompt → LLM 调用 (重试+超时) → 60 字分片 → SSE yield；如需工具则经 config_hub 路由到 mcp_ 工具，结果回灌 LLM。

设计原则：**确定性骨架 (装配/分片/路由) 由 Agent 负责，生成由 LLM 负责**——这是“教学交给 Agent、生成交给 LLM”的具体实现。

核心调用链 (用户问“什么是导数”)

用户输入 → L1(POST /api/teach/stream) → L2(meta_router → intent=teach) → L3(teach_stream: 诊断→计划→讲解→checkpoint→评估→调整) → L4(subagent 协作) → L5(工具按需调用) → L0(防幻觉全程约束)

第 4 章 关键流程

4.1 教学生命周期（序列图要点）

诊断(前置+LLM) → 计划(策略+步骤) → 讲解(学科风格+流式) → 检查(理解) → 评估(掌握度) → 调整(下一轮) → 反思(自我更新)

4.2 自我进化闭环（G1-G11）

教学完成 → 对话历史抓取(G1) → distill 蒸馏(门禁 L1-L3) → evolved 写入(G3 热加载) → KB 可检索；反思 → subject_patches(G5) → 注入下次教学；工具经验(G4/G6/G8) → 反馈学习(SEL-8) → 老化归档(SEL-7)

4.3 RALPH 循环

任务提交(TaskRegistry) → 每轮：执行(executor) → 判定(L0 门禁+L1 指标+L2 证据) → 持久化(快照) → 防呆(五防线) → DONE/ABORT；承诺协议 `<promise>DONE</promise>`

4.4 热加载与配置更新

改 config/*.json → POST /api/admin/reload → config_hub.reload_all() → MCP/skills/hooks/workflows 热更新；evolved 写入 → reload_library → KB 即时可见

4.5 防幻觉锚定

TRUTH_GROUNDING 全模式注入（幕等） → LLM 必须：不编造/信源为绝对命令/允许说不知道 → QualityGate L3 factuality 评分把关自我更新

第 5 章 扩展指南

想做什么	怎么做
新增学科	<code>prompts.py</code> SUBJECT_STYLES 加键 (persona/language/structure/emphasis + 可选 subfield_guide/method_guide/worked_example) + SUBJECT_GRADES/SUBFIELD_TREE
新增 subagent	<code>subagents.py</code> 建类 (run 方法组装 system + 调 _safe_reason_chat) + 注册到 paeg.py
接入 MCP 工具	<code>config/mcp_servers.json</code> 加 server 声明 → 重启/ <code>/api/admin/reload</code> → mcp_ 前缀自动路由
新增 skill	<code>skills/<name>/SKILL.md</code> (frontmatter: name+description + Markdown 正文) → 自动注册
编写 workflow	<code>config/workflows/<name>.json</code> (DAG: steps+depends_on) → run_workflow__ 路由
新增钩子	<code>config/hooks.json</code> 加 {event, module, function} → 事件触发

第 6 章 未来规划 (Roadmap • Oracle 咨询 2026-08-14)

主线：让现有闭环（教学互动 + 评估 + RALPH）具备生产可用性——Q3 补齐工程化短板，Q4 教育语义层升级，2027 产品化。每项挂钩九模块薄弱点或调研成果（非空泛目标）。

Q3 近期 (1-2 月)：工程化补齐 + 闭环数据沉淀

#	目标	价值	依赖	工作量
Q3-1	timeout-policy（教学长任务分级超时+中断恢复）+ llm-retry 合并 harness 统一	防长会话卡死/超时	当前 llm-retry	Short
Q3-2	message-feedback 落地：每轮互动 🍌 / 🍌 + 文本反馈入库 SQLite	给效果评估提供真实数据	message-feedback 子包	Short
Q3-3	session-sqlite 全量替换：会话状态内存/JSON → SQLite（回放）	会话可审计可回放（合规必需）	现有会话管理	Short
Q3-4	九模块薄弱点扫描：对照 §3.12 产出评估覆盖率矩阵	让 Roadmap 可量化	§3.12 文档	Quick
Q3-5	教学能力结构化 v2：teaching-capability 接入 TPACK/加涅元数据标注	能力体系真正接入运行	teaching-capability	Short

Q3 退出条件：生产会话零丢失；≥30% 会话带反馈数据；九模块覆盖矩阵公开。

Q4 中期 (3-4 月)：教育语义层 + 上下文工程统一

#	目标	价值	依赖	工作量
Q4-1	记忆系统语义分层（working/episodic/semantic + 教学知识图谱）	解耦对话与长期认知图谱	Q3-3/Q3-5	Medium
Q4-2	教育知识图谱 MVP（教资 8 模块 × 专业标准 6 能力 × ADDIE）	诊断/画像有“该教什么”依据	教育体系调研	Medium
Q4-3	多 agent 协作（教师+学生+评估 Agent，RALPH 编排不换框架）	Berliner 专家级反思 + LLM-as-judge	Q4-1/ralph	Medium
Q4-4	上下文工程全量统一（预算分配 + 知识图谱检索槽位）	防长会话丢关键上下文	runoob 调研/compaction	Short
Q4-5	RAG 接入语义层（反馈+能力标注+知识图谱为检索源）	画像/策略有据可查	Q4-1/Q4-2/Q3-2	Medium

Q4 退出条件：同一学生 3 次会话可复现认知图谱；多 agent 评估与人工一致率 ≥70%。

2027 远期：产品化方向

#	方向	触发条件	里程碑	工作量
Y-1	个性化自适应闭环成熟（诊断→画像→差异化→评估→反馈全自动）	Q4-3 跑通 ≥1 学科	自适应学习案例	Large
Y-2	教师协作平台（班级薄弱点洞察 + 干预建议 + 策略编辑）	反馈数据 ≥6 个月	教师端 dashboard	Large
Y-3	多模态教学（板书/公式 OCR、语音、图形化思维呈现）	用户具体需求	≥1 学科可用	Large
Y-4	数据洞察 + 学习分析（知识图谱薄弱热力图）	Q4-2 有真实数据	分析报告	Medium

价值-成本矩阵（优先做 ★★★→★★→★）

	低成本	中成本	高成本
高价 值	Q3-1 timeout ★、Q3-3 sqlite ★、Q4-4 上下文统一 ★	Q4-1 记忆分层 ★★、Q4-2 知识图谱 ★★、Q4-3 多 agent ★★	Y-1 自适应闭环 ★★★、Y-2 教师协作 ★★
中价 值	Q3-2 feedback、Q3-5 能力标注	Q4-5 RAG、Y-4 数据洞察	Y-3 多模态
低价 值	Q3-4 评估矩阵	—	—

决策规则（项目所有者）

1. 每条 Roadmap 项必须挂钩：九模块薄弱点 / 教育体系能力 / Harness 包——空泛项砍掉
2. 季度回顾硬指标：Q3 看"零丢失+反馈入库率"，Q4 看"认知图谱可复现"，2027 看"教师实际干预次数"
3. 多 agent 不换框架（复用 RALPH）；知识图谱先轻量本体（JSON）确认需求再上 Neo4j

附录 A 术语表

术语	含义
meta_router	意图路由器（15 意图分类，LLM 优先+规则兜底+模式短路）
SUBJECT_STYLES	35 学科教学风格字典（persona/语言/结构/侧重/方法论/例题）
subagent	领域专家子代理（9 个，职责单一+上下文隔离）
MCP	Model Context Protocol——工具链（filesystem/brave-search 等 25 工具）
Skill	按需加载的专业能力（SKILL.md，L1 目录+L2 激活）
Workflow	声明式流程（JSON DAG，如 teach_minimal 诊断→计划→实施→评估）
hooks	事件钩子（session/message/llm/tool 7 类，waterfall 链）

术语	含义
TRUTH_GROUNDING	防幻觉底线（10 条，全模式注入）
QualityGate	自我更新质量门禁（L1-L4）
RALPH	任务驱动持续改进循环（ralph/ 子系统）
SSE	Server-Sent Events（流式教学输出协议）

附录 B 核心文件索引

文件	职责
server.py	Flask 入口（所有端点 + teach_stream SSE）
paeg.py	教学编排主链（teach() 五阶段）
subagents.py	9 个 subagent + Presenter + 能力清单
prompts.py	提示词库（WEIL_CORE/TRUTH_GROUNDING/SUBJECT_STYLES/build *_system）
meta_router.py	15 意图路由
self_evolution.py	自我更新（蒸馏/补丁/工具经验/老化）
config_hub.py	配置中心（MCP/skills/hooks/workflows 统一）
ralph/	RALPH 循环子系统（6 模块）
pedagogy.py	教学策略选择（画像驱动）
services/	场景 handler（method/study_plan/quiz/keyword_doc 等）+ planner + 生产管线
09_GUI前端/index.html	Web UI（含 checkpoint 问答面板/反馈按钮）